

Introducción al reconocimiento de patrones

M. Sc. Saúl Calderón Ramírez

PARMA-Group, Ingeniería en Computación - Instituto Tecnológico de Costa Rica

21 de agosto de 2017

Index

1 Contexto

2 ¿Qué es el reconocimiento de patrones?

3 Proyectos de PARMA con Aprendizaje Automático

4 Conclusiones y perspectivas

Tendencias del desarrollo científico-tecnológico

- Desde la aparición de las primeras computadoras a finales de la década de los 50's hasta hoy, los computadores digitales han cambiado la manera en como se producen bienes, se administran recursos, nos comunicamos e incluso entretenemos
 - Primera revolución industrial (1760 y 1830): la máquina de vapor y los sistemas mecánicos

Tendencias del desarrollo científico-tecnológico

- Desde la aparición de las primeras computadoras a finales de la década de los 50's hasta hoy, los computadores digitales han cambiado la manera en como se producen bienes, se administran recursos, nos comunicamos e incluso entretenemos
 - Primera revolución industrial (1760 y 1830): la máquina de vapor y los sistemas mecánicos
 - Segunda revolución industrial (1850): la petroquímica, los sistemas eléctricos (radio, telégrafo)

Tendencias del desarrollo científico-tecnológico

- Desde la aparición de las primeras computadoras a finales de la década de los 50's hasta hoy, los computadores digitales han cambiado la manera en como se producen bienes, se administran recursos, nos comunicamos e incluso entretenemos
 - Primera revolución industrial (1760 y 1830): la máquina de vapor y los sistemas mecánicos
 - Segunda revolución industrial (1850): la petroquímica, los sistemas eléctricos (radio, telégrafo)
 - Tercera revolución industrial (1950): sistemas electrónicos, informáticos, biotecnología

Tendencias del desarrollo científico-tecnológico

- Cuarta revolución industrial (en curso?): Convergencia de distintas disciplinas en nuevas áreas transdisciplinarias como la robótica, la inteligencia artificial, nanotecnología, biotecnología, ingeniería biomédica, etc.



Figura: Tomado de <http://www.bbc.com/mundo/noticias-37631834>.

La informática y sus perspectivas

- Automatización a gran escala con sistemas ciberfísicos, usando internet de las cosas, computación en la nube, **aprendizaje automático**, etc. para crear fábricas, procesos y servicios completamente autónomos



Inteligencia Artificial

■ **Inteligencia Artificial:**

- Se ocupa del diseño y construcción de sistemas capaces de percibir datos y señales para aprender, razonar y tomar decisiones de forma autónoma, y desarrolla temas como:
 - Representación del conocimiento

Inteligencia Artificial

■ **Inteligencia Artificial:**

- Se ocupa del diseño y construcción de sistemas capaces de percibir datos y señales para aprender, razonar y tomar decisiones de forma autónoma, y desarrolla temas como:
 - Representación del conocimiento
 - Búsqueda heurística

Inteligencia Artificial

■ **Inteligencia Artificial:**

- Se ocupa del diseño y construcción de sistemas capaces de percibir datos y señales para aprender, razonar y tomar decisiones de forma autónoma, y desarrolla temas como:
 - Representación del conocimiento
 - Búsqueda heurística
 - **Aprendizaje automático**

Inteligencia Artificial

■ **Inteligencia Artificial:**

- Se ocupa del diseño y construcción de sistemas capaces de percibir datos y señales para aprender, razonar y tomar decisiones de forma autónoma, y desarrolla temas como:
 - Representación del conocimiento
 - Búsqueda heurística
 - **Aprendizaje automático**

Aprendizaje automático

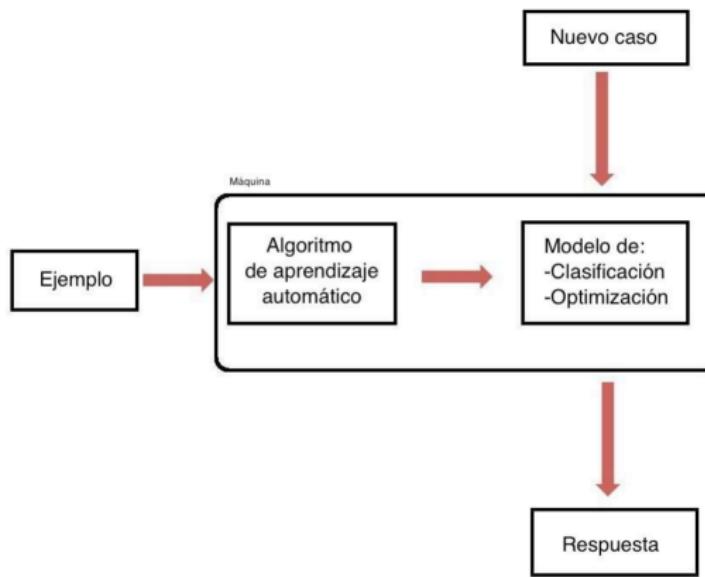
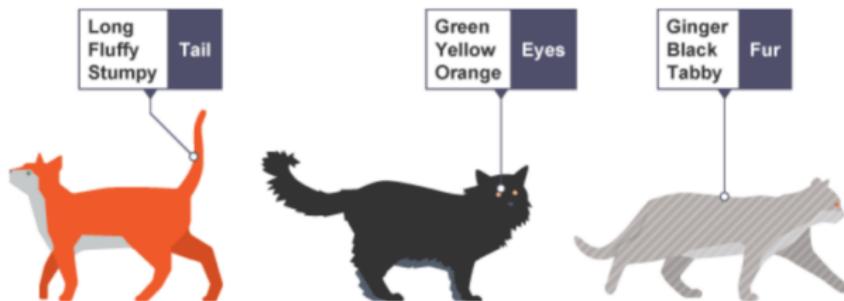


Figure: Aprendizaje Automático: Se encarga de desarrollar métodos y algoritmos de descripción, clasificación y regresión de datos

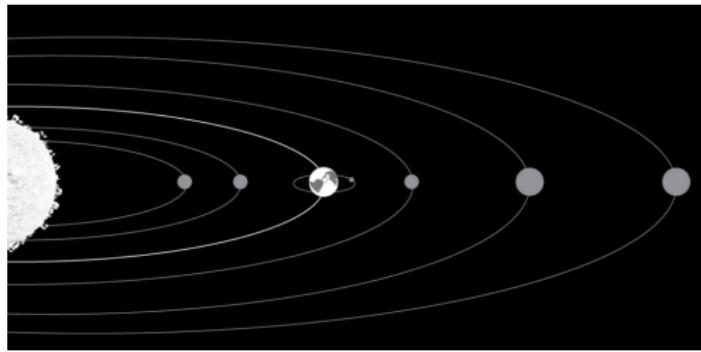
¿Qué es el reconocimiento de patrones (RP)?

- Diariamente realizamos muchas actividades de RP: desde buscar manzanas maduras para comer en una canasta del supermercado, hasta comprender sonidos y palabras escritas
- RP (según Richard Duda): Acto de tomar un conjunto de datos y categorizarlos o clasificarlos según un «patrón»



¿Qué es el reconocimiento de patrones (RP)?

- **La búsqueda de patrones ha sido una tarea fundamental en la ciencia:** P. ej, la búsqueda de repeticiones sistemáticas (patrones) en conjuntos de datos realizada por Johannes Kepler, permitió el modelado de las leyes empíricas



¿Qué es el reconocimiento de patrones (RP)?

- **RP como disciplina:** Se encarga de desarrollar métodos y algoritmos de descripción y clasificación de datos
- **Áreas relacionadas:**
 - **Matemática aplicada:** análisis numérico, optimización, probabilidad y estadística, matemática discreta

¿Qué es el reconocimiento de patrones (RP)?

- **RP como disciplina:** Se encarga de desarrollar métodos y algoritmos de descripción y clasificación de datos
- **Areas relacionadas:**
 - **Matemática aplicada:** análisis numérico, optimización, probabilidad y estadística, matemática discreta
 - **Ingeniería eléctrica:** análisis y procesamiento de señales, procesamiento digital de señales

¿Qué es el reconocimiento de patrones (RP)?

- **RP como disciplina:** Se encarga de desarrollar métodos y algoritmos de descripción y clasificación de datos
- **Areas relacionadas:**
 - **Matemática aplicada:** análisis numérico, optimización, probabilidad y estadística, matemática discreta
 - **Ingeniería eléctrica:** análisis y procesamiento de señales, procesamiento digital de señales
 - **Computación:** inteligencia artificial, aprendizaje automático, minería de datos, estructuras de datos y análisis de algoritmos, teoría de grafos, etc

¿Qué es el reconocimiento de patrones (RP)?

- **RP como disciplina:** Se encarga de desarrollar métodos y algoritmos de descripción y clasificación de datos
- **Areas relacionadas:**
 - **Matemática aplicada:** análisis numérico, optimización, probabilidad y estadística, matemática discreta
 - **Ingeniería eléctrica:** análisis y procesamiento de señales, procesamiento digital de señales
 - **Computación:** inteligencia artificial, aprendizaje automático, minería de datos, estructuras de datos y análisis de algoritmos, teoría de grafos, etc
 - Linguistica, física, biología, química, etc....

Aplicaciones del RP, ML, Minería de datos, etc

- Sistemas para facilitar tareas en áreas como la medicina, agricultura, química, industria etc.

Aplicaciones del RP, ML, Minería de datos, etc

- Sistemas para facilitar tareas en áreas como la medicina, agricultura, química, industria etc.
- Motores de búsqueda, análisis de datos para toma de decisiones en organizaciones: minería de datos, «big data» o «ciencias de los datos»

Aplicaciones del RP, ML, Minería de datos, etc

- Sistemas para facilitar tareas en áreas como la medicina, agricultura, química, industria etc.
- Motores de búsqueda, análisis de datos para toma de decisiones en organizaciones: minería de datos, «big data» o «ciencias de los datos»
- Sistemas robotizados usan algoritmos de ML más sofisticados



Figura: Proyecto del automóvil sin conductor de Google

Definiciones: Característica o «Feature»

- **Característica:** propiedad individual medible u observable: p. ej en el mundo real; forma, color, olor, sabor, textura, tamaño, peso, brillo



Definiciones: Característica o «Feature»

- **Verdosidad:** $\overrightarrow{x} \in [0 - 255]$ intensidad promedio en una imagen del color «verde» captado por una cámara digital



Definiciones: Dimensionalidad de una muestra

- **Dimensionalidad de una muestra** $\dim(\vec{x}_i)$: Una muestra se representa con un arreglo de $\dim(\vec{x}_i) = N$ valores correspondientes a múltiples características:

$$\vec{x}_i = \langle x_1, x_2, \dots, x_N \rangle$$

Definiciones: Dimensionalidad de una muestra

- **Dimensionalidad de una muestra** $\dim(\vec{x}_i)$: Una muestra se representa con un arreglo de $\dim(\vec{x}_i) = N$ valores correspondientes a múltiples características:

$$\vec{x}_i = \langle x_1, x_2, \dots, x_N \rangle$$

- **Ejemplo 1**, una muestra \vec{x}_a puede estar compuesta por los valores particulares de características de **color y peso**, en este caso $N = 2$:

$$\vec{x}_a = \langle x_1 = 253, x_2 = 40 \text{ gramos} \rangle$$

Definiciones: Dimensionalidad de una muestra

- **Dimensionalidad de una muestra** $\dim(\vec{x}_i)$: Una muestra se representa con un arreglo de $\dim(\vec{x}_i) = N$ valores correspondientes a múltiples características:

$$\vec{x}_i = \langle x_1, x_2, \dots, x_N \rangle$$

- **Ejemplo 1**, una muestra \vec{x}_a puede estar compuesta por los valores particulares de características de **color y peso**, en este caso $N = 2$:

$$\vec{x}_a = \langle x_1 = 253, x_2 = 40 \text{ gramos} \rangle$$

- **Ejemplo 2**, una muestra \vec{x}_b puede estar definida por los valores particulares de una imagen de 100×100 pixeles, por lo que $N = 10000$

Definiciones: Patrón

- **Patrón o «plantilla»:** Regularidad discernible para una o varias características en un conjunto de objetos o **muestras**



Definiciones: Conjunto de muestras

- **Conjunto de muestras X :** Conjunto de M muestras de un arreglo de características:

$$\mathbf{X} = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_M\}$$

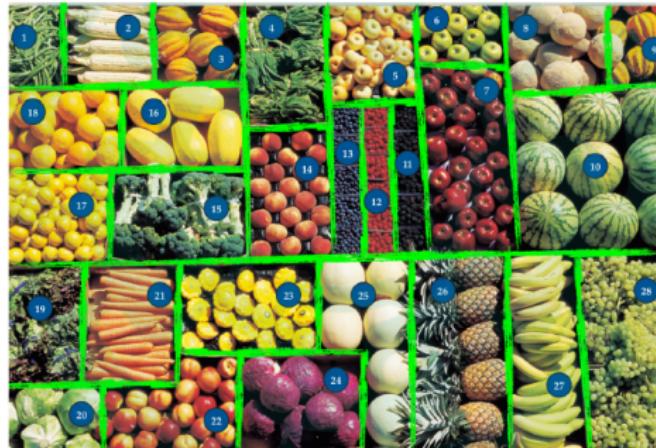
- Por ejemplo, ¿cuál es el patrón para las muestras de la verdosidad ($\dim(\vec{x}_i) = 1 = N$):

$$\mathbf{X} = \{\vec{x}_1 = 253, \vec{x}_2 = 254, \vec{x}_3 = 100, \vec{x}_4 = 255\}$$



Definiciones: Clase

- **Clase:** Abstracción de propiedades comunes o repetidas en múltiples instancias de esa clase

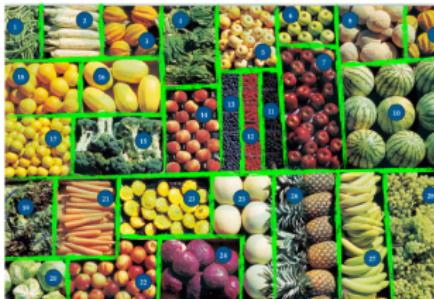


Definiciones: Clase

- **Clase:** Para facilitar su representación una clase C_j tiene asociada una etiqueta $j = 1, 2, \dots, J$
- **Ejemplo 1:** la clase «banano» tiene etiqueta $j = 1$, la clase «sandía» la etiqueta $j = 2$

Definiciones: Clase

- **Clase:** Para facilitar su representación una clase C_j tiene asociada una etiqueta $j = 1, 2, \dots, J$
- **Ejemplo 1:** la clase «banano» tiene etiqueta $j = 1$, la clase «sandía» la etiqueta $j = 2$
- **Ejemplo 2:** la clase «uva verde» $j = 1$, «uva morada» $j = 2$ y «uva roja» $j = 3$



Definiciones: Conjunto de etiquetas

- **Conjunto de etiquetas T para un conjunto de muestras X :**
Para un conjunto de M muestras

$$\mathbf{X} = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_M\}$$

existe un conjunto de etiquetas «correctas»:

$$\mathbf{T} = \{t_1, t_2, \dots, t_M\}$$

Definiciones: Conjunto de etiquetas

- **Conjunto de etiquetas T para un conjunto de muestras X :**
Para un conjunto de M muestras

$$X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_M\}$$

existe un conjunto de etiquetas «correctas»:

$$T = \{t_1, t_2, \dots, t_M\}$$

- Para el ejemplo de las uvas:

$$X = \{\vec{x}_1 = 253, \vec{x}_2 = 254, \vec{x}_3 = 100, \vec{x}_4 = 255\}$$

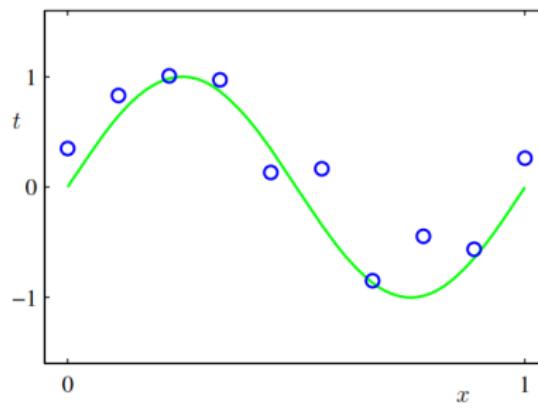
$$T = \{t_1 = 1, t_2 = 1, t_3 = 2, t_4 = 1\}$$

Definiciones: Clasificación

- **Clasificación:** Proceso de asignar una muestra \vec{x}_i una etiqueta j , y en general para un conjunto de muestras X , obtener un conjunto de etiquetas T

Definiciones: Clasificación

- **Clasificación:** Proceso de asignar una muestra \vec{x}_i una etiqueta j , y en general para un conjunto de muestras X , obtener un conjunto de etiquetas T
- Si todas las etiquetas $j \in \mathbb{N}$ se realiza una **clasificación** y si $j \in \mathbb{R}$ se realiza una **regresión**



Definiciones: Un clasificador estadístico simple: Uvas verdes, moradas y rojas

- Se define el conjunto de **muestras de entrenamiento (ground truth)** X_e con sus correspondientes etiquetas T_e

$$\begin{aligned}X_e &= \{\vec{x}_1 = 253, \vec{x}_2 = 254, \vec{x}_3 = 100, \vec{x}_4 = 255, \vec{x}_5 = 105\} \\T_e &= \{t_1 = 1, t_2 = 1, t_3 = 2, t_4 = 1, t_5 = 2\}\end{aligned}$$

Definiciones: Un clasificador estadístico simple: Uvas verdes, moradas y rojas

- Se define el conjunto de **muestras de entrenamiento (ground truth)** X_e con sus correspondientes etiquetas T_e

$$\begin{aligned}X_e &= \{\vec{x}_1 = 253, \vec{x}_2 = 254, \vec{x}_3 = 100, \vec{x}_4 = 255, \vec{x}_5 = 105\} \\T_e &= \{t_1 = 1, t_2 = 1, t_3 = 2, t_4 = 1, t_5 = 2\}\end{aligned}$$

- Momentos estadísticos para cada clase:

$$\begin{array}{lll}\mu_1 = 254 & \sigma_1 = & 1 \\ \mu_2 = 102,5 & \sigma_2 = & 3,53\end{array}$$

Definiciones: Un clasificador estadístico simple: Uvas verdes, moradas y rojas

- Se define el conjunto de **muestras de entrenamiento (ground truth)** X_e con sus correspondientes etiquetas T_e

$$\begin{aligned}X_e &= \{\vec{x}_1 = 253, \vec{x}_2 = 254, \vec{x}_3 = 100, \vec{x}_4 = 255, \vec{x}_5 = 105\} \\T_e &= \{t_1 = 1, t_2 = 1, t_3 = 2, t_4 = 1, t_5 = 2\}\end{aligned}$$

- Momentos estadísticos para cada clase:

$$\begin{array}{lll}\mu_1 = 254 & \sigma_1 = & 1 \\ \mu_2 = 102,5 & \sigma_2 = & 3,53\end{array}$$

- Si se recibe una nueva muestra, p. ej. con valor $\vec{x}_6 = 252$, el clasificador hace para todas las clases C_j :

$$\begin{aligned}|\mu_1 - \vec{x}_6| &= 2 < 3\sigma_1 \\ |\mu_2 - \vec{x}_6| &= 149,5 > 3\sigma_2 \Rightarrow t_6 = 1\end{aligned}$$

Definiciones: Clasificación

Muestra	Características			Clase
	Peso	Forma	Tamaño	
	liviano	redondo	pequeño	uva
	mediano	alargado	mediano	banano
	pesado	ovalada	grande	sandía

Etapas básicas de un Sistema RP (SRP)

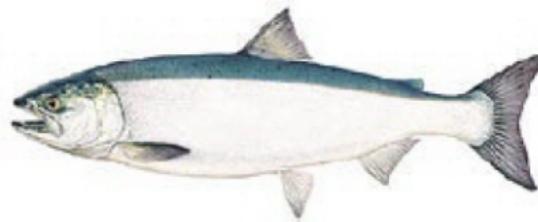


Etapas básicas de un Sistema RP: Ejemplo

- Una empacadora de pescados necesita construir una máquina para etiquetar los róbalos (sea-bass) y salmones empacados



(a)



(b)

Etapas básicas de un Sistema RP: Ejemplo

- Ahí van los pescados...

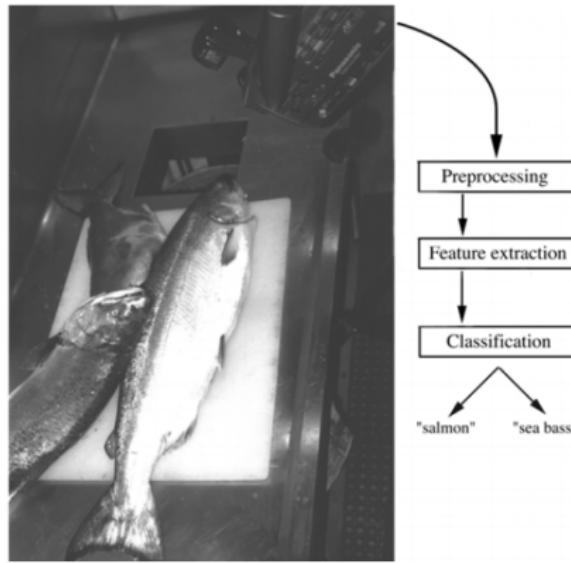


Figura: Muestras de pescados a clasificar (Tomado de Duda, Hart.)

Etapas básicas: Preprocesamiento

- Sean los datos entrantes al sistema $\mathcal{U} = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión $\dim(\vec{u}_i) = B$

Etapas básicas: Preprocesamiento

- Sean los datos entrantes al sistema $U = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión $\dim(\vec{u}_i) = B$
- Muchas veces son preprocesados para eliminar o atenuar el «ruido» en los datos, aplicando una función

$$F(\vec{u}_i) = \vec{v}_i$$

que presenta como salida a \vec{v}_i , correspondiente a la muestra preprocesada, con dimensión $\dim(\vec{u}_i) = B$

Etapas básicas: Preprocesamiento

- Sean los datos entrantes al sistema $\mathbf{U} = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión $\dim(\vec{u}_i) = B$
- Muchas veces son preprocesados para eliminar o atenuar el «ruido» en los datos, aplicando una función

$$F(\vec{u}_i) = \vec{v}_i$$

que presenta como salida a \vec{v}_i , correspondiente a la muestra preprocesada, con dimensión $\dim(\vec{u}_i) = B$

- **Función F** : Desde el procesamiento de señales: Filtros en el dominio de Fourier, Wavelets, DCT, etc

Etapas básicas: Preprocesamiento

- Por ejemplo, si las entradas son imágenes de 640×480 pixeles, entonces $\dim(\vec{u}_i) = 307200$



Etapas básicas: Extracción de características

- **Entrada:** conjunto de datos preprocesados

$V = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión
 $\dim(\vec{u}_i) = B$

Etapas básicas: Extracción de características

- **Entrada:** conjunto de datos preprocesados

$\mathbf{V} = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión $\dim(\vec{u}_i) = B$

- Consiste en un funcional

$$G(\vec{v}_i) = \vec{x}_i$$

con una salida \vec{x}_i , correspondiente al vector de características y dimensión $\dim(\vec{u}_i) = N$

Etapas básicas: Extracción de características

- **Entrada:** conjunto de datos preprocesados

$V = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}$, con cada muestra de dimensión $\dim(\vec{u}_i) = B$

- Consiste en un funcional

$$G(\vec{v}_i) = \vec{x}_i$$

con una salida \vec{x}_i , correspondiente al vector de características y dimensión $\dim(\vec{u}_i) = N$

- **Función G :** Por cada muestra la función extrae un arreglo de características para la fácil discriminación de las clases, y **reducir la dimensionalidad** $N \ll B$

- Procesamiento de señales, con info. específica del dominio (medicina, biología, química, etc)

Etapas básicas: Extracción de características

- **Entrada:** conjunto de datos preprocesados

$$V = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}, \text{ con } \dim(\vec{u}_i) = 307200$$

Etapas básicas: Extracción de características

- **Entrada:** conjunto de datos preprocesados

$$V = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_M\}, \text{ con } \dim(\vec{u}_i) = 307200$$

- **Salida:** El funcional $G(\vec{v}_i) = \vec{x}_i = \langle x_1, x_2 \rangle$ extrae características de **ancho** del pescado, y a la «**claridad**» del **color** del pescado

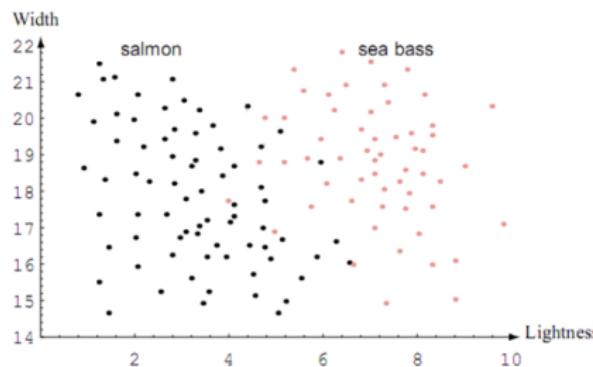


Figura: Diagrama de dispersión del espacio de muestras con dimensión $N = 2$

Etapas básicas: Clasificación, no paramétrica

- **K vecinos más cercanos:** Para un punto nuevo \vec{x}_a , se calculan los $K = 6$ vecinos más cercanos, usando la distancia Euclídea,
- En este caso $t_a = 1$ (C_1 corresponde a la clase salmón)

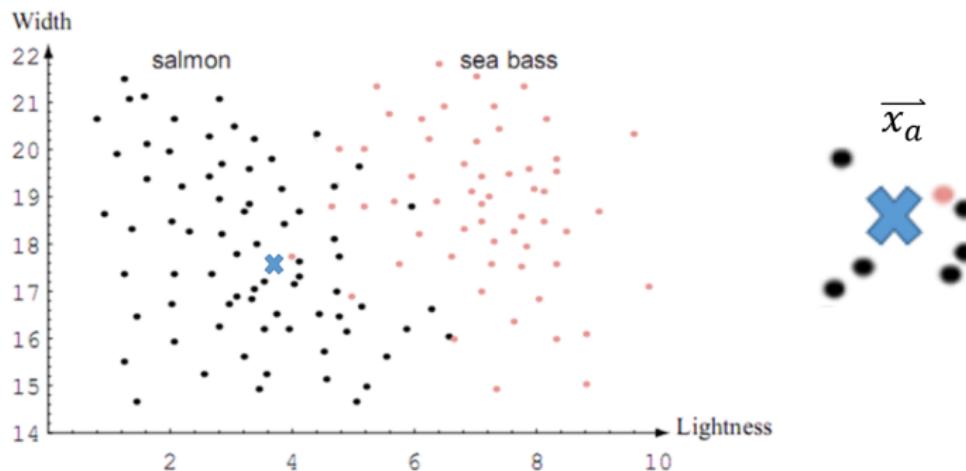


Figura: Espacio de muestras de entrenamiento \mathbf{X}_e , con $N = 2$ ▶ ▷ ⏪ ⏪ ⏴ ⏴

Etapas básicas: Clasificación, paramétrica lineal

- Dado un conjunto de muestras de entrenamiento X_e , **construye un hiperplano o función** y que minimice el error de clasificación
- Error cuadrático mínimo regularizado, discriminante lineal de Fisher, perceptrón, etc

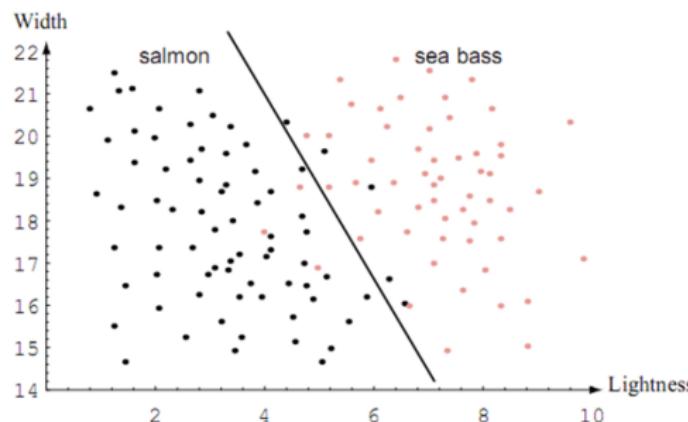


Figura: Espacio de muestras de entrenamiento X_e , con $N = 2$

Etapas básicas: Clasificación, superficie no lineal

- Clasificadores más sofisticados generan superficies de decisión no lineales (máquinas de soporte vectorial, redes neuronales, convolucionales, Bayesianas, etc)

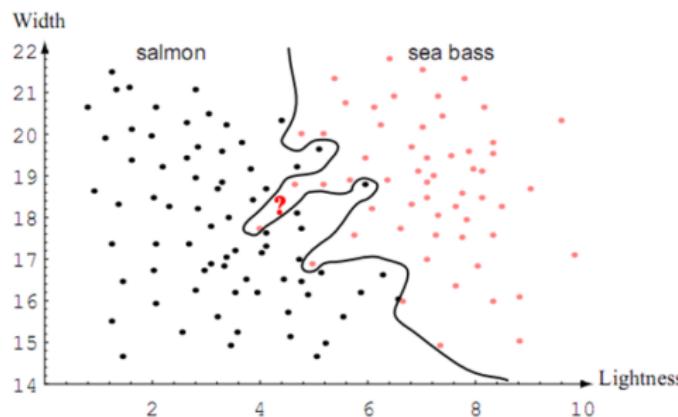


Figura: Sobre ajuste: Una superficie que se sobreajusta, confía al 100% en X_e lo cual no es aconsejable...

Etapas básicas: Clasificación, superficie no lineal

- Clasificadores más sofisticados generan superficies de decisión no lineales (máquinas de soporte vectorial, redes neuronales, convolucionales, Bayesianas, etc)

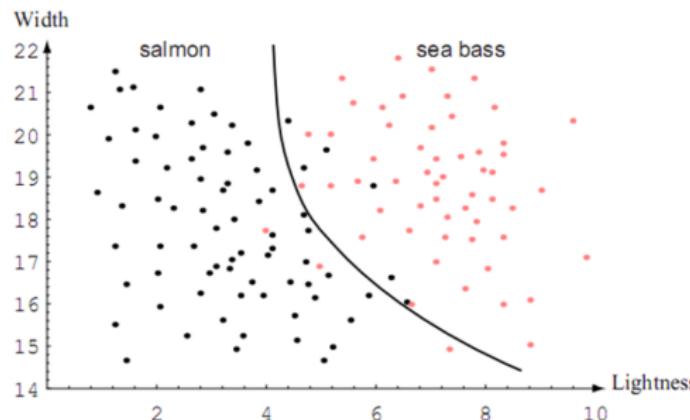


Figura: Mejores resultados con superficies regularizadas, para evitar sobreajuste

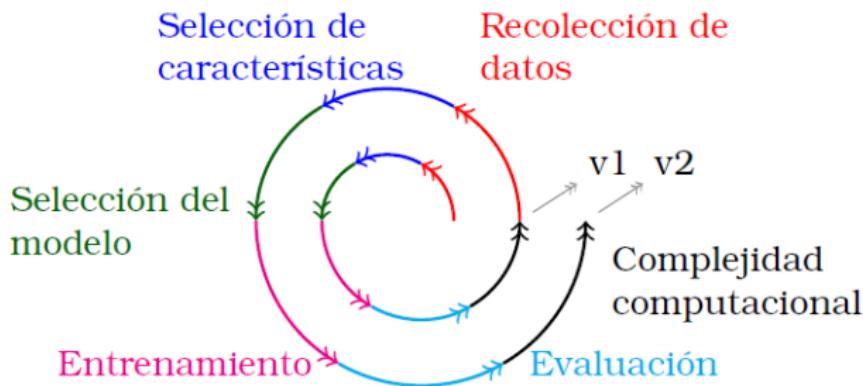
Etapas básicas: Clasificación no supervisada

- Los clasificadores anteriores necesitan un conjunto de muestras etiquetadas X_e , por lo que se les dice **supervisados**
- **No supervisados:** «amontonan» los datos para encontrar por sí solos las muestras de cada clase J

(Loading...)

Figura: Funcionamiento del algoritmo K-medias.

Ciclo de vida de un SRP



PARMA-Group

Objetivos

- Investigación: Estimular la investigación en el área de aprendizaje automático, proyectos con otras universidades, nacionales e internacionales

PARMA-Group

Objetivos

- Investigación: Estimular la investigación en el área de aprendizaje automático, proyectos con otras universidades, nacionales e internacionales

- Docencia: Crear y asesorar cursos relacionados para carreras de pregrado y posgrado

Reconocimiento de patrones y aprendizaje automático en el TEC: PARMA-Group

Objetivos

- Extensión: Realizar investigación y desarrollo de soluciones basadas en el aprendizaje automático, en conjunto con otras instituciones

Reconocimiento de patrones y aprendizaje automático en el TEC: PARMA-Group

Objetivos

- Extensión: Realizar investigación y desarrollo de soluciones basadas en el aprendizaje automático, en conjunto con otras instituciones
- Estimular la organización de actividades de capacitación a estudiantes y profesores, y profesionales en el área (proc. señales, aprendizaje automático, minería de datos)

Reconocimiento de patrones y aprendizaje automático en el TEC: PARMA-Group

- Luis Alexander: Modelos de predicción para la agricultura (a partir de datos climatológicos)
- Juan Luis Crespo: Modelos de atención para máquinas, redes neuronales, dispositivo de asistencia ventricular, tratamiento de información genética, etc.

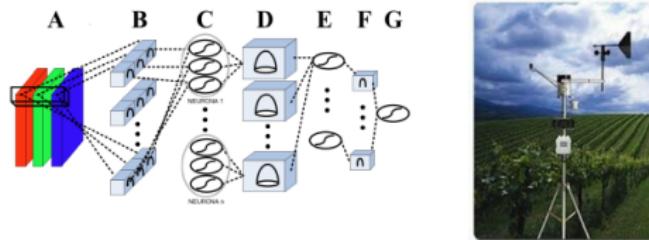


Figure: Izq. redes neuronales gaussianas, der. datos meteorológicos para la predicción de enfermedades

Reconocimiento de patrones y aprendizaje automático en el TEC: PARMA-Group

- Geovanni Figueroa, Erick Mata y Jose Carranza: Reconocimiento de árboles a partir de imágenes digitales de corte en troncos y hojas
- Esteban Arias: Comparación de rutas metabólicas

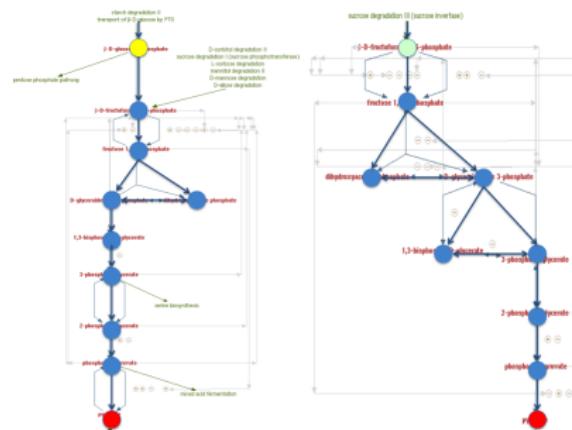
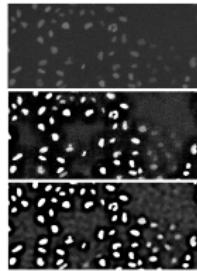


Figure: Comparación de rutas metabólicas con grafos

Preprocesamiento, segmentación y rastreo de células

- PARMA-Group (TEC): *A first glance on the enhancement of digital cell activity videos from glioblastoma cells with nuclear staining, CONCAPAN 2016*
- DNLM-IFFT: An Implementation of the Deceived Non Local Means Filter using \\Integral Images and the Fast Fourier Transform for a Reduced Computational Cost, CIARP 2017



Análisis automático de Histologías

- Sistema de apoyo de diagnostico de histiologias prostaticas , en conjunto con el Dr. Jose Luis Quirós (Hospital Max Peralta) y la Dra. Tilcia López (Hospital Calderón Guardia) López

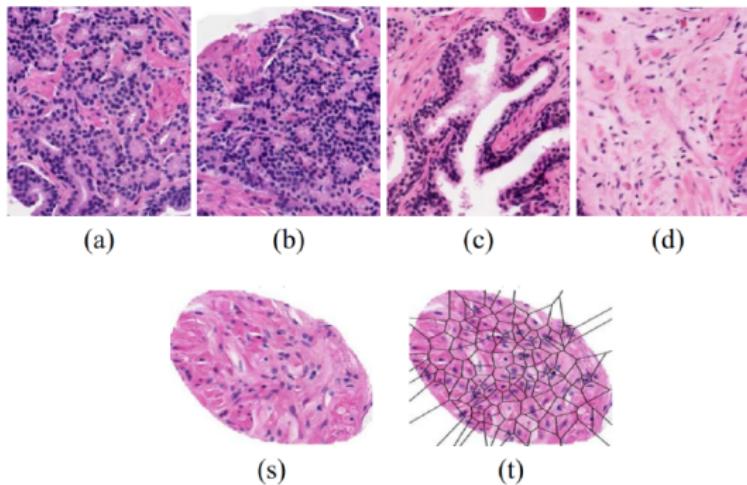


Figure: Histologías de próstata

Análisis automático de Histologías

- **Etapa actual:** Recopilacion, etiquetado de imagenes, estudio de tecnicas de segmentacion , extraccion de caracteristicas y clasificacion

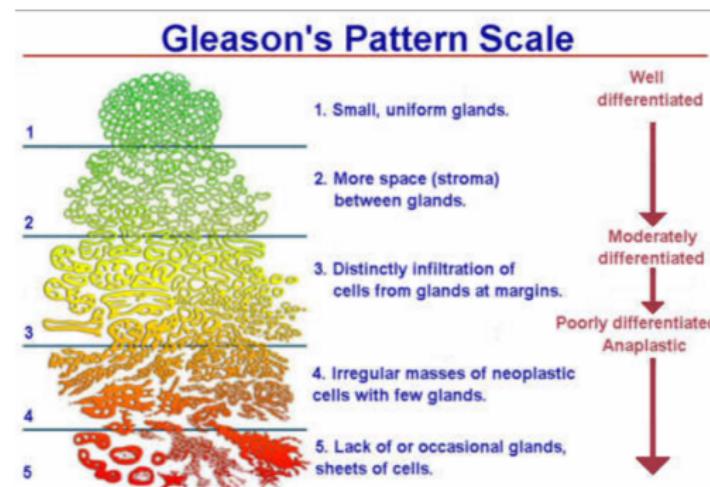


Figure: Escala de Gleason

Estimación de productividad de cultivos a partir de imágenes multi-espectrales

- Iniciativa de proyecto conjunto con la Universidad EARTH, laboratorio de agricultura de precisión

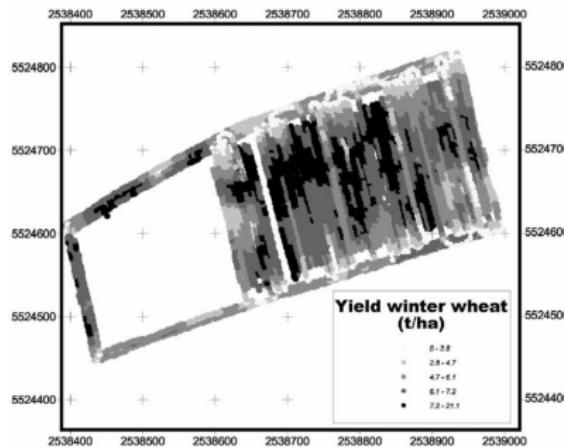


Figure: Ejemplo de estimación de productividad por hectárea

Competencia: Estimación de edad a partir de imágenes radiológicas

- Competencia en conjunto con equipos de la Universidad de Toronto y la Universidad de Ljubljana



Figure: Imagen del conjunto de muestras

Identificación de Especies de Plantas usando Pliegos de Herbario

- Existen millones de fotos de pliegos de herbario hechas públicas a través de iniciativas como iDigBio.
- Tiene mucho ruido visual por el tipo de manipulación que se les da sin tener fines tecnológicos en mente.
- Hipótesis: Técnicas como Deep Learning permiten clasificar a nivel de especies, género y familia con buena exactitud.



cirad

inria
INVENTEURS DU MONDE NUMÉRIQUE

Figure: Colaboraciones.

Aprendizaje automático en el futuro

- Los algoritmos y máquinas que aprenden a partir de los datos se incorporan a las distintas esferas de la vida con mucha velocidad

Aprendizaje automático en el futuro

- Los algoritmos y máquinas que aprenden a partir de los datos se incorporan a las distintas esferas de la vida con mucha velocidad
- **Retos:** formación en áreas relacionadas (matemáticas, ciencias de la computación, estadística) y transdisciplinar

Aprendizaje automático en el futuro

- Los algoritmos y máquinas que aprenden a partir de los datos se incorporan a las distintas esferas de la vida con mucha velocidad
- **Retos:** formación en áreas relacionadas (matemáticas, ciencias de la computación, estadística) y transdisciplinar
- Alrededor de 7.1 millones de trabajos serán eliminados, y 2.1 millones creados (<http://money.cnn.com>)